

人福药物研发数据标准 1.0

适用范围: 临床前药物研发数据管理与交换

覆盖阶段: 靶点识别 → 候选化合物提名

编写依据: 药物研发领域通用数据实践

目录

- 引言与定位
- 核心领域对象模型
- 药物研发阶段模型
- 受控词汇与枚举标准
- 风险分类标准
- 证据模型与知识表示
- 决策与治理数据标准
- 知识管理数据架构
- 数据溯源与审计标准
- 外部标准对齐
- 与行业数据标准的关系
- 附录：实体关系概览

1. 引言与定位

1.1 数据标准定位

本标准定义临床前药物研发数据的核心规范，涵盖项目（Program）、靶点（Target）、候选化合物（Candidate）、实验（Experiment）、证据（Evidence）、风险（Risk）、决策（Decision）等核心数据实体的定义、字段规范、受控词汇和关联规则。不涉及特定平台的实现细节，包括但不限于用户角色管理、访问控制机制、权限矩阵等系统层设计。

1.2 领域范围

本标准覆盖的药物研发数据域：

数据域	说明
项目/计划 (Program)	药物研发项目，包含靶点、药物模式 (Modality)、适应症、阶段、团队
靶点 (Target)	生物学靶点，包含基因、蛋白质、机制、可成药性评分
候选化合物 (Candidate)	小分子、抗体、蛋白质等候选实体，含结构与性质数据
证据 (Evidence)	多源证据（实验、计算、文献、专利、会议、历史决策）
风险 (Risk)	多维度风险（有效性、选择性、PK、安全性、可开发性等）
决策 (Decision)	项目决策记录，含支持/反对证据、替代方案、结果
实验 (Experiment)	实验设计、执行、结果与结论
假说 (Hypothesis)	可验证的科学假说及其验证状态
推荐 (Recommendation)	AI 生成的行动推荐、风险缓解建议

1.3 设计原则

数据模型遵循以下原则：

- **溯源第一 (Provenance First):** 每一条数据都记录来源、创建者、时间戳和变更历史
 - **不可变日志 (Append-Only Log):** 关键事件以只追加方式记录，永不删除
 - **受控词汇 (Controlled Vocabulary):** 所有分类字段使用预定义枚举，禁止自由文本
 - **版本化 (Versioning):** 决策、证据等关键实体支持版本管理，旧版本不可删除
 - **可审计 (Auditable):** 所有变更携带 before/after 状态，哈希完整性校验
 - **角色感知 (Role-Aware):** 数据可见性和操作权限基于 10 种角色 + 6 级表示级别
-

2. 核心领域对象模型

2.1 对象清单（31 个领域对象）

#	对象	英文名	描述
1	用户	User	平台用户，含角色与部门
2	项目	Program	药物研发项目核心实体
3	靶点	Target	生物学靶点（基因/蛋白）
4	候选化合物	Candidate	候选分子/抗体/蛋白质
5	假说	Hypothesis	可验证的科学假说
6	实验	Experiment	实验方案与结果
7	数据集	Dataset	来源标识的数据集
8	证据	Evidence	源引证据，含置信度与分类
9	风险	Risk	项目风险，分类别与严重度
10	决策	Decision	项目决策，含完整上下文
11	推荐	Recommendation	AI 生成的推荐
12	任务	Task	可分配的任务
13	行动	Action	结构化行动，含10态状态机
14	假设前提	Assumption	需要验证的假设前提 (Assumption)
15	项目成员	ProgramMember	项目团队成员与角色
16	外部合作伙伴	ExternalPartner	CRO/CDMO 等外部实体
17	任务包	TaskPackage	外部合作伙伴工作包

#	对象	英文名	描述
18	专利	Patent	专利，含申请人、日期、相关性
19	FTO 标记	FTOFlag	自由实施权障碍标记
20	信号	Signal	外部信号（文献/专利/竞品/监管）
21	声明	Claim	知识图谱中的科学声明
22	工作流	Workstream	DMTA 工作流
23	评审	Review	实体评审记录
24	批准	Approval	实体批准记录
25	会议	Meeting	项目会议记录
26	疾病	Disease	疾病实体，含 ICD 编码
27	资产	Asset	项目相关文件资产
28	请求	Request	通用请求追踪
29	语义节点	SemanticNode	知识图谱节点（靶点/候选/生物标志物等）
30	语义边	SemanticEdge	知识图谱关系
31	本体条目	OntologyEntry	共享科学本体条目

2.2 核心对象标准字段

所有领域对象遵循统一的基础标准：

```
class DomainBaseModel:
    """域模型的基类"""
    # 配置:
    # - populate_by_name=True (支持字段别名反序列化)
    # - str_strip_whitespace=True (自动去除首尾空格)
    # - use_enum_values=True (枚举序列化为字符串值)
    # - from_attributes=True (支持从 ORM 对象构建)
```

```
class TimestampMixin:
    created_at: datetime    # UTC 时区, 创建时间
    updated_at: datetime    # UTC 时区, 最后更新时间

class UUIDMixin:
    id: str                 # UUIDv4 字符串格式
```

2.3 实体关联标准

所有领域对象通过以下方式互联:

- **引用 ID 列表** (`xxx_ids: list[str]`): 表达多对多关系, 如 `related_candidates`、`supporting_evidence_ids`
- **外键字段** (`xxx_id: str`): 表达所属关系, 如 `program_id`、`target_id`
- **反向引用**: 通过查询服务实现, 不在模型中持有冗余数据

2.4 候选化合物数据标准


`Candidate` 模型统一定义了小分子与生物制剂的共同数据结构:

字段	类型	说明
candidate_type	str	small_molecule, antibody, protein, peptide, oligonucleotide 等
structure_data	dict	小分子结构信息 (SMILES、InChI 等)
sequence_data	dict	生物制剂序列信息 (氨基酸序列、修饰等)
properties	dict	理化/生物性质键值对, 含 ADMET 参数
developability_score	float	0-1 可开发性综合评分
safety_flags	list[str]	安全性预警标签

3. 药物研发阶段模型

3.1 项目阶段 (ProgramStage)

本标准定义了 11 个当前活跃阶段 + 6 个兼容阶段，覆盖从信号接收到项目归档的完整临床前生命周期：



当前阶段定义

阶段	值	描述
信号接收	intake	接收、筛选和分类内外部研究信号
靶点评估	target_assessment	靶点成药性、生物机制、竞争格局评估
项目立项	program_setup	项目章程、团队组建、资源分配
活跃 DMTA	active_dmta	设计-合成-测试-分析迭代周期
先导优先级	lead_prioritization	多个先导化合物的对比与排序
PCC 评估	pcc_assessment	临床前候选化合物全面评估
外部合作	external_collaboration	CRO/CDMO 外部工作协调
IP/FTO 审查	ip_fto_review	知识产权与自由实施权审查
提名	nomination	候选化合物正式提名与证据包
关闭	closeout	项目终止或转换
归档	archived	项目归档，保留只读记忆

兼容阶段（旧版）

target_identification、target_validation、hit_discovery、
lead_optimization、candidate_nomination、ind_enabling

3.2 药物模式 (Modality)

模式	值	说明
小分子	small_molecule	化学小分子药物
生物制剂	biologics	抗体、蛋白质、多肽、寡核苷酸等
两者	both	同时涉及小分子和生物制剂

3.3 DMTA workflow阶段 (WorkstreamPhase)

阶段	值
设计	design
合成	make
测试	test
分析	analyze

4. 受控词汇与枚举标准

所有分类字段均使用 `StrEnum` 枚举，禁止自由文本输入。

4.1 置信度级别 (ConfidenceLevel)

级别	值	适用场景
极低	very_low	未经证实、单一来源、大量冲突
低	low	有限证据、部分冲突
中	medium	有证据支持但未充分验证（默认值）
高	high	多源证据一致支持
极高	very_high	多源、多方法、人类评审确认


4.2 证据类型 (EvidenceType)

类型	值	来源示例
实验数据	experimental	生物化学测定、细胞实验、动物模型
计算数据	computational	分子对接、分子动力学、QSAR 模型
文献	literature	PubMed、预印本、会议摘要
专利	patent	专利文献
会议记录	meeting	项目会议、评审会议
历史决策	prior_decision	前序项目的决策记录

4.3 陈述分类 (StatementClassification)

分类	值	说明
事实	fact	可被实验验证的客观陈述
推论	inference	基于数据的分析和推理
推荐	recommendation	对后续行动的建议

4.4 行动状态机 (ActionStatus)



状态	值	含义
建议	suggested	AI 建议或系统触发的初步行动
草稿	drafted	人类编写的草稿
已指派	assigned	已指派给具体人员
已接受	accepted	负责人接受任务
进行中	in_progress	正在执行
待审查	review_needed	需要审查后才能完成
已完成	completed	成功完成
已拒绝	rejected	被指派者拒绝
已阻塞	blocked	被依赖项阻塞
已取代	superseded	被更新的行动取代

4.5 决策状态机 (DecisionStatus)



状态	值
建议	proposed
审阅中	in_review
就绪	ready
已批准	approved
已拒绝	rejected
已推迟	deferred
已关闭	closed
已取代	superseded

4.6 决策结果 (DecisionOutcome)

结果	值	含义
继续推进	proceed	批准继续下一阶段
推迟	defer	等待更多数据后重新决策
停止	stop	终止当前方向
调整	modify	变更方案后继续

4.7 信号类型与状态

信号类型 (SignalType)

类型	值
论文	paper
专利	patent
竞品	competitor
靶点	target
资产	asset
模式	modality
会议	conference
监管	regulatory

信号状态 (SignalStatus)

new → assigned → under_review → escalated / declined / converted

4.8 参与者标准

参与类型 (ParticipationType)

类型	值
负责人	owner
核心贡献者	core_contributor
专家审阅者	specialist_reviewer
执行者	executor
批准者	approver
观察者	observer
外部合作伙伴	external_partner

4.9 推荐类型 (RecommendationType)

类型	值	描述
下一步最佳行动	next_best_action	当前应优先执行的行动
下一步最佳实验	next_best_experiment	应优先设计的实验
决策准备	decision_prep	辅助决策的证据汇编
风险缓解	risk_mitigation	降低特定风险的措施
跨职能评审	cross_functional_review	需要多职能团队评审的场景
外部分配	external_assignment	需要委托给 CRO/CDMO 的工作

4.10 声明类型与状态 (ClaimType / ClaimStatus)

类型	值	状态	值
事实	fact	活跃	active
解释	interpretation	被质疑	challenged
假设	hypothesis	被取代	superseded
		已废弃	deprecated

4.11 推荐状态 (RecommendationStatus)

状态	值
草稿	draft
待审查	pending_review
已批准	approved
已拒绝	rejected
已实施	implemented
已取代	superseded

4.12 workflow执行状态 (WorkflowStatus)

状态	值
待处理	pending
运行中	running
已完成	completed
失败	failed
待批准	awaiting_approval

4.13 评审与批准状态

评审状态 (ReviewStatus)

状态	值
待处理	pending
进行中	in_progress
已通过	approved
已拒绝	rejected

批准状态 (ApprovalStatus)

状态	值
待处理	pending
已批准	approved
已拒绝	rejected
已推迟	deferred

5. 风险分类标准

5.1 风险类别 (RiskCategory)

类别	值	覆盖的风险域
有效性	efficacy	靶点-化合物效力、体内疗效不足
选择性	selectivity	脱靶活性、选择性窗口不足
药代动力学	pk	吸收、分布、代谢、排泄特征不佳
安全性	safety	毒性、安全性药理学、遗传毒性
可开发性	developability	溶解性、稳定性、聚集、免疫原性
可制造性	manufacturing	合成复杂度、放大、成本、质量控制
知识产权	ip	专利侵犯、FTO 障碍、排他性不足
运营	operational	资源、时间线、团队、CRO 依赖

5.2 风险严重度 (RiskSeverity)

级别	值	响应标准
低	low	记录跟踪，定期审查
中	medium	制定缓解计划（默认）
高	high	主动缓解，项目级关注
严重	critical	需立即行动，可能阻断阶段推进

5.3 风险字段标准

Risk:	
category: RiskCategory	# 类别（受控枚举）
severity: RiskSeverity	# 严重度（受控枚举）
probability: float (0-1)	# 发生概率
impact_description: str	# 影响描述
mitigation_plan: str	# 缓解计划
related_candidates: list[str]	# 关联候选化合物
related_evidence: list[str]	# 支持风险的证据
related_decisions: list[str]	# 与风险相关的决策
detection_date: datetime	# 发现日期
resolution_date: datetime	# 解决日期

6. 证据模型与知识表示

6.1 证据数据标准

证据模型遵循"声明 + 溯源 + 置信度"结构:

Evidence:	
statement: str	# 证据陈述（人类可读）
evidence_type: EvidenceType	# 证据类型（受控枚举）
confidence: ConfidenceLevel	# 置信度（受控枚举）
classification: StatementClassification	# 事实/推论/推荐
supports: bool	# 支持或反对某个论点
source_system: str	# 来源系统
source_reference: str	# 来源引用
source_dataset_id: str	# 关联数据集
is_source: bool	# 是否为源头证据
supersedes_id: str	# 取代的证据
contradictory_evidence_ids: list	# 矛盾证据
related_candidates/hypotheses/risks: list	# 关联实体
extracted_by: str	# 提取者（人类或 AI agent）
extracted_at: datetime	# 提取时间
review_status: str	# 审查状态
status: str	# 活跃/过期/被取代

6.2 证据新鲜度标准

证据具有时效性，不同来源的证据有不同的衰减曲线：

证据类型	衰减周期
实验数据 (experimental)	180 天
计算数据 (computational)	90 天
文献 (literature)	365 天
专利 (patent)	730 天
会议记录 (meeting)	30 天
历史决策 (prior_decision)	180 天

新鲜度分级：**VERY_FRESH** → **FRESH** → **AGING** → **STALE** → **VERY_STALE**
其中 VERY_FRESH (≤30天)、FRESH (≤90天)、AGING (≤180天)、STALE (≤365天)、VERY_STALE (>365天)

6.3 知识图谱标准

通过语义层维护知识图谱，节点类型包括：

实体类型	entity_type	说明
靶点	target	生物学靶点实体
候选化合物	candidate	候选化合物实体
生物标志物	biomarker	生物标志物实体
负债	liability	已知的安全性/可开发性负债
决策	decision	决策节点

6.4 关系类型

语义关系采用 主语-谓语-宾语 三元组模式：

```
SemanticClaim:
  subject: str          # 主语实体 (如 "Target X")
  predicate: str        # 谓语关系 (如 "is_linked_to", "shows_aggregation
                        _risk")
  object: str           # 宾语实体 (如 "biomarker Y")
  claim_text: str        # 人类可读声明
  confidence: str        # 置信度
  evidence_ids: list     # 支持该声明的证据
  source_program_ids: list # 来源项目
  temporal_validity: str  # active/superseded/deprecated
  superseded_by: str      # 被哪个新声明取代
```

6.5 本体条目标准

共享科学本体的数据标准：

```
OntologyEntry:
  term_id: str          # 术语 ID
  term: str             # 术语名称
  category: str         # 分类
  definition: str        # 定义
  synonyms: list[str]   # 同义词
  parent_terms: list[str] # 父术语
  child_terms: list[str]  # 子术语
  related_programs: list[str] # 关联项目
  usage_count: int       # 使用次数
```

7. 决策与治理数据标准

7.1 决策质量评分

每个决策通过 5 个维度评估质量，产出 A-F 等级：

维度	字段	权重
证据强度	evidence_strength	25%
证据平衡性	evidence_balance	20%
理由完整性	rationale_completeness	25%
替代方案考量	alternative_consideration	15%
风险确认	risk_acknowledgment	15%

7.2 阶段门控标准 (Stage-Gate Criteria)

项目从一个阶段推进到下一阶段前，必须通过可配置的门控：

```
StageGateReadiness:
  readiness_score: float           # 整体准备度评分
  criteria_results:                # 各条件通过情况
    - criterion: str
      met: bool
      required: bool
  blocking_issues: list[str]       # 阻断性问题
  evidence_completeness: float     # 证据完整度
  risk_readiness: float            # 风险就绪度
  decision_readiness: float        # 决策就绪度
  experiment_readiness: float      # 实验就绪度
```

7.3 批准场景标准

系统定义了 8 个强制人工批准场景：

场景	说明
program_initiation	新项目启动
pcc_readiness	PCC 准备就绪声明
candidate_nomination	候选化合物提名
candidate_deprioritization	候选化合物降级
external_data_sharing	对外数据共享
ip_fto_disclosure	IP/FTO 相关披露
high_impact_conversion	高影响 AI 建议转行动
stage_gate	阶段门控通过

8. 知识管理数据架构

8.1 五层知识数据模型

(1) 证据存储 (Evidence Store)

不可变的、源引支持的证据库，支持混合检索（关键词 + 元数据过滤 + 向量相似度）

```
EvidenceQuery:
  program_id: str          # 项目 ID
  query_text: str          # 自然语言查询
  evidence_types: list     # 按证据类型过滤
  confidence_levels: list  # 按置信度过滤
  supports: bool           # 按支持/反对过滤
  source_systems: list     # 按来源系统过滤
  candidate_ids: list      # 按候选化合物过滤
  date_from/date_to: datetime # 时间范围
```

(2) 项目事件日志 (Program Event Log)

只追加不可变的时序记录:

```
ProgramEventEntry:
    event_type: str          # decision, evidence, assumption_change, risk_change
    event_timestamp: datetime # 事件时间
    actor_id: str            # 执行者
    entity_type: str         # 实体类型
    entity_id: str           # 实体 ID
    action: str              # created, updated, approved, rejected, superseded
    description: str         # 描述
    provenance_hash: str     # 溯源哈希
```

(3) 语义记忆 (Semantic Memory)

科学声明、实体、关系的知识图谱:

```
SemanticEntity:
    entity_id: str
    entity_type: str        # target, candidate, biomarker, liability, hypothesis
    label: str
    aliases: list[str]
    properties: dict
    source_program_ids: list[str]

SemanticRelationship:
    source_entity_id: str
    target_entity_id: str
    relationship_type: str
    confidence: float (0-1)
    evidence_ids: list[str]
```

(4) 程序性记忆 (Procedural Memory)

可复用的 workflow 模板和操作手册:

```
ProceduralMemoryEntry:
    workflow_name: str          # weekly_program_review, candidate_comparis
on 等
    workflow_type: str
    version: int
    steps: list[dict]          # 步骤定义
    templates: dict            # 输出模板
    success_count: int          # 成功次数
    failure_count: int          # 失败次数
```

(5) 派生摘要 (Derived Summaries)

始终可从源事件重新生成的摘要:

```
MemorySummary:
    summary_type: str          # program_status, evidence_review, decision
_log
    time_period_start/end: datetime
    content: str               # 摘要内容
    source_event_ids: list      # 来源事件 ID (可重新生成)
    is_regenerable: bool = True # 始终标记为可重新生成
```

8.2 跨项目知识共享

```
# 共享实体的跨项目发现
GET /memory/entities/shared?entity_type=target&program_ids=...

# 跨项目声明查询
POST /memory/claims/search
{
  "query": "...",
  "entity_types": ["target"],
  "confidence_min": 0.7
}

# 知识转移
POST /memory/knowledge-transfer
{
  "entity_type": "target",
  "source_program_id": "X",
  "target_program_id": "Y",
  "entities": ["..."]
}
```

9. 数据溯源与审计标准

9.1 审计追踪 (AuditRecord)

所有变更操作都生成审计记录：


```
AuditRecord:
  record_id: str
  timestamp: datetime (UTC)
  user_id: str
  action: str
  severity: str          # low, medium, high, critical
  entity_type: str       # 操作的实体类型
  entity_id: str         # 实体 ID
  before_state: dict     # 变更前状态（完整快照）
  after_state: dict      # 变更后状态
  change_summary: str    # 变更摘要
  hash: str              # 完整性校验哈希
  ip_address: str
  policy_violations: list # 任何策略违规
  red_team_flags: list   # 任何红队标记
```

9.2 证据不可变性

- **源头证据不可修改:** `is_source=True` 的证据创建后不可直接更新
- **超过 24 小时的记录不可编辑:** 更新操作创建新版本并 `supersedes_id` 指向前版本
- **选择性遗忘不删除:** 遗忘操作仅去优先级、标记弃用或归档，永不物理删除记录

9.3 AI 输出监控 (ModelOutputMonitor)

所有 AI 生成输出都被监控和记录：

```
ModelOutputMonitor:
  model_name: str
  model_version: str
  prompt: str          # 输入 prompt
  output: str           # AI 输出
  hallucination_flags: list[str] # 幻觉标记
  bias_flags: list[str]   # 偏见标记
  safety_flags: list[str] # 安全标记
  human_reviewed: bool    # 是否经人类审查
  review_outcome: str     # 审查结果
```

9.4 数据治理规则

数据治理遵循以下通用规则：

- 1. 决策须有证据支持
- 2. 严重风险须经人类审查
- 3. 不得允许无监督 AI 决策
- 4. 置信度阈值（低于 High 的 AI 结论须标记）
- 5. 数据须有溯源来源

10. 外部标准对齐

10.1 已引用的外部标准

标准	字段	说明
ICD 疾病编码	Disease.icd_code	国际疾病分类编码
UniProt 蛋白质标识	Target.uniprot_id	蛋白质数据库标识符
基因符号	Target.gene_symbol	HGNC 标准基因命名
UTC 时间戳	所有时间字段	统一使用 UTC 时区

10.2 ADMET 评估标准

ADMET 评估标准涵盖 5 个维度：

维度	关键词	评估内容
A (吸收)	Absorption	溶解度、渗透性、Caco-2、PAMPA
D (分布)	Distribution	血浆蛋白结合、VD、BBB 穿透
M (代谢)	Metabolism	CYP 酶抑制、代谢稳定性、反应性代谢物
E (排泄)	Excretion	清除率、半衰期、排泄途径
T (毒性)	Toxicity	hERG、AMES、肝毒性、光毒性

10.3 生物制剂可开发性标准

生物制剂可开发性评估标准涵盖以下维度：

- CDR 区域分析
- 翻译后修饰位点（脱酰胺、氧化、异构化）检测
- 聚集倾向性评估
- T-cell 表位预测
- 可制造性（表达水平、纯化可行性）

11. 与行业数据标准的关系

11.1 CDISC 标准 (SDTM / ADaM / SEND)

本标准 **不直接采用** CDISC 标准，因 CDISC 标准主要适用于临床研究及监管递交数据（SDTM 制表数据、ADaM 分析数据、SEND 非临床安全评估数据）。本标准聚焦临床前发现阶段，但在数据治理理念上与 CDISC 一致：

- 受控词汇的使用（Controlled Terminology）
- 元数据管理和数据溯源
- 标准化的数据结构定义

11.2 FAIR 数据原则

本标准的定义隐含地遵循 FAIR 原则：


原则	对应措施
Findable 可发现	URI/UUID 标识、结构化元数据、可检索
Accessible 可访问	标准化数据接口与查询规范
Interoperable 可互操作	基于 JSON Schema 的标准化数据格式、受控词汇
Reusable 可重用	跨项目知识共享机制、版本管理、来源引用

11.3 ALCOA+ 数据完整性原则

本标准的数据治理定义遵循 ALCOA+ 原则：

原则	对应措施
Attributable 可归属	全部数据记录操作者身份 (actor_id)
Legible 清晰可读	结构化字段约束、枚举受控词汇
Contemporaneous 同步	时间戳统一使用 UTC 时区
Original 原始	源头数据标记 is_source ，不可直接修改
Accurate 准确	版本控制、变更前后状态记录
Complete 完整	证据链接到支持/反对/矛盾关系
Consistent 一致	统一的时间戳标准、枚举约束、外键引用
Enduring 持久	只追加事件日志、派生摘要可重新生成
Available 可用	知识管理架构支持跨项目查询与共享

12. 附录：实体关系概览



维护说明: 本文件应随数据模型定义变更而同步更新。任何新增枚举值、新增实体字段或修改状态机行为时，需在本文件中补充对应的标准说明。